

PROJE DOKÜMANTASYONU

Versiyon 1.0 | 26.07.2026

Yıpranma Tespit Modeli – Teknik Dokümantasyon

1. Proje Özeti

Bu proje, bir üretim hattında insan gözünün fark edemeyeceği yüzey çiziklerini görüntü işleme ile otomatik olarak tespit etmeyi hedeflemektedir. Segmentasyon tabanlı derin öğrenme modeli sayesinde ürün fotoğraflarındaki **çizik**, **göçük** ve **yıpranma** gibi kusurlar piksel düzeyinde belirlenir. İki farklı YOLO segmentasyon modelinin birleştirilmesiyle (ensemble) hassasiyet ve geri çağırma (recall) arasında denge kurulmuş, tek modelin kaçırdığı kusurlar dahi yakalanmıştır.

- **Amaç:** Montaj hattında kalite kontrolünü iyileştirmek; insan kaynaklı hataları en aza indirmek.

- **Kapsam:** Son tüketiciye sunulmaya hazır ürün fotoğrafları üzerinde gerçek zamanlıya yakın çıkarım.

- **Çıktı:** Her görüntü için kusur maskeleri ve istatistiksel raporlar.

2. Giriş

Geleneksel kalite kontrol sistemlerinde operatörler, hızlı akan bant üzerinde mikro boyutlu çizikleri sıklıkla gözden kaçıırır. Bu projede **Ultralytics YOLO** segmentasyon altyapısı kullanılarak eğitilen modeller, 1280×1280 çözünürlükte yüksek başarımla çalışmakta; ayrıca iki farklı modelin tahminleri (confidence öncelikli kümeleme ile birleştirilen maskeler) sayesinde hem tek modelin tespit edemediği ancak diğerinin güvenle yakaladığı bölgeler işaretlenmekte hem de ortak kararlar pekiştirilmektedir. Proje kapsamında veri seti oluşturmak için gerçek ürün fotoğraflarına yapay zekâ destekli kusurlar eklenmiş ve **Roboflow** platformu üzerinden etiketleme yapılmıştır.

3. Kullanılan Teknolojiler

PROJEDE KULLANILAN TEKNOLOJİLER

Katman	Araç / Kütüphane	Açıklama
 Programlama Dili	 Python 3.10+	Ana geliştirme ortamı ve tüm süreçlerin uygulandığı temel programlama dilidir.
 Derin Öğrenme Çatısı	 ultralytics YOLOv8	YOLO tabanlı segmentasyon modelinin eğitimi, doğrulanması ve çıkarım işlemlerini sağlayan derin öğrenme çatısıdır.
 Model Mimarisi	 YOLO26 _m yolo26m-seg.pt	Çizik ve kusur bölgelerinin piksel seviyesinde tespit edilmesi için kullanılan orta boyutlu segmentasyon modelidir.
 Veri Artırımı	 Gemini	Gerçek görüntülere yapay kusurlar ekleyerek eğitim veri setinin çeşitliliğini ve genelleme yeteneğini artırmak için kullanılmıştır.
 Etiketleme	 roboflow	Segmentasyon maskelerinin oluşturulması, düzenlenmesi ve veri setinin yönetimi için kullanılan platformdur.
 Görüntü İşleme	 OpenCV  NumPy	Görüntü ön işleme, maske birleştirme, görselleştirme ve yardımcı görüntü işleme işlemleri için kullanılmıştır.
 Donanım Hızlandırma	 NVIDIA CUDA	Model eğitimi ve çıkarım süreçlerinin GPU üzerinde paralel olarak hızlandırılmasını sağlamaktadır.
 Versiyon Kontrolü	 git	Kaynak kodlarının, deneylerin ve model sürümlerinin yönetimi ile değişiklik takibinde kullanılmıştır.

4. Sistem Mimarisi

4.1. Genel Akış

...

[Gerçek Ürün Fotoğrafları]

|



[Gemini AI – Yapay Kusur Ekleme]

|



[Roboflow – Maske Etiketleme]

|



[Ultralytics YOLO Eğitimi (Python)]

├─ model_37.pt

└─ model_39.pt

|



[Ensemble Pipeline (Python)]

|



[Sonuç Görüntüleri / Raporlar]

...

4.2. Ensemble (Birleştirme) Altyapısı

İki farklı modelin aynı görüntü üzerindeki tahminleri şu mantıkla birleştirilir:

1. Her model kendi tahminlerini maskeler, bounding box, sınıf ve confidence değerleri ile üretir.
2. Tüm tahminler confidence değerine göre büyükten küçüğe sıralanır.
3. Greedy yöntemle mask-IoU (Intersection over Union) $\geq$ `iou\_thres` (varsayılan 0.5) olan aynı sınıfa ait tahminler birleştirilir; maskeler OR işlemiyle genişletilir, box en kapsayan hale getirilir, confidence en yüksek olan korunur.
4. Tek bir modelin bulduğu ancak diğerinin hiç tahmin üretmediği bölgeler **kesikli sarı çerçeve** ile vurgulanır; iki modelin hemfikir olduğu ortak tahminler normal sınıf renginde çizilir.

Bu sayede:

- **model_37**'nin güçlü olduğu bölgeler ile **model_39**'un güçlü olduğu bölgeler bir araya gelir.
- Duplicate (mükerrer) tahminler elenir.
- Tek modelin kaçırduğu kusurlar görünür hale gelir.

5. Veri Etiketleme Süreci

5.1. Ham Veri Toplama

İnternet üzerindeki alışveriş sitelerinden ve markaların resmî sayfalarından satışa hazır ürün fotoğrafları indirilmiştir. Bu fotoğraflar yüksek çözünürlüklü, farklı açılardan ve aydınlatma koşullarından seçilmiştir.

5.2. Yapay Kusurların Eklenmesi

Gemini AI kullanılarak her fotoğrafa rastgele pozisyonlarda ve boyutlarda çizik, göçük ve yıpranma efektleri uygulanmıştır. Böylece gerçek üretim ortamında karşılaşılabilecek kusurların simülasyonu yapılmış, etiketlenebilecek geniş bir veri varyasyonu oluşturulmuştur.



5.3. Etiketleme (Roboflow)

- Kusur eklenmiş fotoğraflar **Roboflow** platformuna yüklenmiştir.
- Polygon tabanlı segmentasyon aracı ile her bir çizik/göçük bölgesi `defect` sınıfı altında etiketlenmiştir.
- Veri seti %85 eğitim, %10 doğrulama, %5 test olarak bölünmüştür.
- Roboflow'un sunduğu otomatik artırma (augmentation) opsiyonları ihtiyaca göre kullanılmamış, augmentasyon işlemleri yalnızca eğitim kodu içindeki `degrees`, `translate`, `scale` vb. parametrelerle gerçekleştirilmiştir.
- Son veri seti `dataset.yaml` formatında dışa aktarılmıştır.

6. Kullanıcı Arayüzü

Proje şu an için bir grafik arayüze (GUI) sahip değildir; tüm işlemler komut satırı (CLI) üzerinden Python betikleri ile yürütülür.

6.1. Eğitim Başlatma

```
```bash
```

```
python train.py
```

```
```
```

`train.py` içerisinde `mode\_train()` fonksiyonu ön tanımlı hiperparametrelerle çağrılır. `dataset.yaml` dosyasının aynı dizinde bulunması beklenir. Eğitimin yarıda kalması durumunda:

```
```bash
```

```
python train_resume.py
```

```
```
```

çalıştırılarak en son kaydedilen `last.pt` ağırlığından devam edilir.

6.2. Tek Görüntüde Çıkarım

```
``bash
python predict.py
...`
```

Bu betik varsayılan olarak `test.png` üzerinde çalışır; `conf=0.10` hassasiyetle tahmin yapar ve sonuçları hem ekrana basar hem de `runs/segment/predict` altına maskeleriyle birlikte kaydeder.

6.3. Çoklu Görüntüde Çıkarım

```
``bash
python multi_predict.py
...`
```


Belirtilen klasördeki (`test\_veri`) tüm görseller işlenir, sonuçlar `proje adi/test\_sonuc\_lari` altında saklanır.

6.4. Ensemble Çıkarım

```
``bash
python multiple_predict.py \
  --models model_37.pt model_39.pt \
  --source ./test_veri \
  --conf 0.15 \
  --iou 0.5 \
  --batch 8 \
  --save-dir ensemble_results
...`
```

Parametreler:

- `--models`: Birleştirilecek model ağırlık dosyaları (sıralı).
 - `--source`: Tek görsel ya da klasör yolu.
 - `--conf`: Confidence eşiği (düşük tutulabilir, ensemble eleme yapar).
 - `--iou`: Maskeleri birleştirme eşiği.
 - `--batch`: GPU üzerinde aynı anda işlenecek görüntü sayısı.
 - `--save-dir`: Çıktıların kaydedileceği klasör.
 - `--show`: Her işlenen görüntüyü ekranda göstermek için opsiyonel.
- Çıktı dosyaları `\*\_ensemble.png` adıyla kaydedilir. Aynı isim çakışmasında `\_v0`, `\_v1` ... şeklinde numaralandırılır.



7. Sonuç ve Değerlendirme

- **Başarımlar:** Proje, ürün yüzeyindeki mikro kusurları yüksek doğrulukla segmentleyebilen iki ayrı YOLO modeli ortaya çıkarmıştır. Ensemble yöntemi ile:
 - Tek model eksiklikleri (false negative) önemli ölçüde azaltılmış,
 - Mükerrer tahminler (false positive) temizlenmiş,
 - Operatörün yalnızca şüpheli bölgelere odaklanması sağlanmıştır.
- **Sınırlılıklar:** Veri seti tamamen yapay kusurlarla oluşturulduğu için gerçek üretim hatlarında farklı tipte kusurlarla karşılaşıldığında modelin genelleme performansı düşebilir. Yalnızca statik fotoğraflar üzerinde test edilmiştir; video akışında performans ayrıca optimize edilmelidir.
- **Gelecek Çalışmalar:**
 - Gerçek üretim hattından toplanan fotoğraflarla veri setini zenginleştirme.
 - Modeli istenilen dışındaki diğer makinaların verisi ile de eğitip model güölendirme .
 - Ensemble yöntemini üç veya daha fazla modele ölçeklendirme.

Doküman Sürümü: 1.0

Son Güncelleme: 2025-04-02